

ANALIZA POTENCJALNYCH KANDYDATÓW NA MODEL

Regresja Logistyczna (Logistic Regression)

- **Sposób działania:** Algorytm wykorzystuje matematyczną funkcję sigmoidalną do przekształcenia wyników równania liniowego na prawdopodobieństwo z przedziału od 0 do 1. Model stara się poprowadzić optymalną hiperpłaszczyznę (prostą w wielu wymiarach), która oddzieli transakcje legalne od oszustw.
- **Zalety:** Bardzo duża szybkość trenowania i predykcji.
- **Wady:** Zakłada liniową zależność między cechami a zmienną docelową. Słabo radzi sobie z wysoce niezbalansowanymi klasami bez dodatkowych manipulacji progami odcięcia.
- **Dopasowanie do problemu:** Z analizy macierzy korelacji wynika, że w zbiorze dominują zależności nieliniowe. Regresja logistyczna prawdopodobnie osiągnie najgorsze wyniki co może sugerować konieczność zastosowania bardziej zaawansowanych algorytmów

2. Sieć Neuronowa (Multi-Layer Perceptro)

- **Sposób działania:** Składa się z warstwy wejściowej, warstw ukrytych oraz warstwy wyjściowej. Pojedyncze neurony przetwarzają sygnały wejściowe z użyciem wag i nieliniowych funkcji aktywacji (np. ReLU). Model uczy się poprzez propagację wsteczną (backpropagation), minimalizując błąd predykcji iteracyjnie.
- **Zalety:** Zdolność do aproksymacji niemal każdej, nawet najbardziej skomplikowanej funkcji nieliniowej bez konieczności ręcznej inżynierii cech.
- **Wady:** Wymaga restrykcyjnego skalowania danych. Działa jak "czarna skrzynka", co w przypadku systemu bankowego uniemożliwia łatwe wytłumaczenie decyzji o zablokowaniu przelewu. Ze względu na dużą liczbę parametrów, na małych zbiorach ma ogromną tendencję do przeuczenia (overfittingu).
- **Dopasowanie do problemu:** Zbiór może okazać się niewystarczający do optymalnego wytrenowania sieci (zbyt mało danych). Dodatkowo model ten trudno dostosować do niezbalansowanych klas.

3. Drzewo Decyzyjne (Decision Tree Classifier)

- **Sposób działania:** Algorytm dzieli zbiór danych na coraz mniejsze podzbiory na podstawie wartości poszczególnych cech (np. `anomaly_score > 0.5`). Wynikiem jest struktura przypominająca drzewo, z korzeniem na górze i liśćmi (decyzjami) na dole.

- **Zalety:** Intuicyjność i pełna interpretowalność (drzewo można łatwo zwizualizować). Nie wymaga skalowania danych i naturalnie radzi sobie z brakami korelacji liniowych.
- **Wady:** Rozbudowane drzewa mają silną tendencję do uczenia się na pamięć danych treningowych, co skutkuje drastycznym spadkiem skuteczności na danych testowych.
- **Dopasowanie do problemu:** Drzewo decyzyjne z łatwością wyłapie nieliniowe wzorce w naszych danych i zidentyfikuje wiodącą rolę wskaźnika anomalii. Prawdopodobnie będzie jednak zbyt niestabilne.

4. Las Losowy (Random Forest Classifier)

- **Sposób działania:** Algorytm tworzy "las" złożony z setek niezależnych drzew decyzyjnych. Każde drzewo trenowane jest na losowej próbce danych (ze zwracaniem) oraz ocenia losowy podzbiór zmiennych. Ostateczna decyzja (czy to oszustwo?) zapada poprzez demokratyczne głosowanie wszystkich drzew.
- **Zalety:** Bardzo wysoka skuteczność i stabilność. Redukuje problem przeuczenia. Świetnie radzi sobie z danymi tabelarycznymi o różnych typach.
- **Wady:** Wymaga więcej mocy obliczeniowej i pamięci niż pojedyncze modele. Traci bezpośrednią interpretowalność (nie można prześledzić jednej ścieżki decyzyjnej), ponieważ to „czarna skrzynka”.
- **Dopasowanie do problemu:** Model ten jest bardzo solidnym kandydatem. Skutecznie poradzi sobie z brakiem liniowości i uodporni system na pojedyncze skrajne przypadki w danych.

5. XGBoost (Extreme Gradient Boosting)

- **Sposób działania:** Również jest to model zespołowy oparty na drzewach, ale w przeciwieństwie do Lasu Losowego, wykorzystuje technikę "Boostingu". Drzewa nie są budowane niezależnie, lecz sekwencyjnie. Każde kolejne drzewo analizuje i koryguje błędy popełnione przez swojego poprzednika, co prowadzi do niezwykle precyzyjnego dopasowania.
- **Zalety:** Najwyższa skuteczność w większości problemów tabelarycznych. Posiada wysoce zoptymalizowane algorytmy przyspieszające obliczenia.
Kluczowa zaleta: zawiera wbudowane parametry (np. `scale_pos_weight`) dedykowane do obsługi skrajnie niezbalansowanych zbiorów.
- **Wady:** Wrażliwy na szum w danych. Posiada dużą liczbę hiperparametrów, co sprawia, że jego optymalizacja bywa skomplikowana i czasochłonna.

- **Dopasowanie do problemu:** (Potencjalnie najlepszy?) Jego wbudowane mechanizmy radzenia sobie z niezbalansowanymi danymi (nasze 12.5% oszustw) oraz zdolność do modelowania nieliniowych wzorców przy jednoczesnej odporności na współliniowość czynią go idealnym wyborem do stworzenia precyzyjnego detektora oszustw finansowych.