

## PODZIAŁ

| Kto?                | Co?                                                                    |
|---------------------|------------------------------------------------------------------------|
| Marcin Zubowski     | Wybór zestawu danych, analiza cech, typy zmiennych,                    |
| Karolina Antonowicz | Wybór zestawu danych, wykresy, korelacje                               |
| Borys Maksymiuk     | Wybór zestawu danych, definicja celów, szukanie istniejących rozwiązań |

## Założenia projektu, istniejące podejścia

Celem modelu jest zbadanie wpływu poszczególnych cech na identyfikację oszustw bankowych oraz dalsza optymalizacja modelu by ograniczyć ilość potrzebnych cech bez znacznego negatywnego wpływu na skuteczność detekcji. Pozwoli to stwierdzić które cechy są kluczowe w przypadku oszustw bankowych, a które mają marginalny wpływ, końcowo pomagając w optymalizacji i poprawieniu skuteczności modelu.

Prace dotyczące tego zagadnienia:

- “Fraud Detection in Banking Transactions Using Machine Learning” - Rampala Harshitha, Dande Anusha, Manoj Venkatesh, Bhuvana S ([https://www.researchgate.net/publication/403195321\\_Fraud\\_Detection\\_in\\_Banking\\_Transactions\\_Using\\_Machine\\_Learning](https://www.researchgate.net/publication/403195321_Fraud_Detection_in_Banking_Transactions_Using_Machine_Learning)) - w tej pracy zbiór danych zawiera mniej cech, model oparty jest na lesie losowym. Osiągnięto skuteczność na poziomie 92-92%.
- “Impact of Artificial Intelligence on Fraud Detection in Retail Banking: A Quantitative Study” - Javeed Iqbal, Zia Ullah Khan ([https://www.researchgate.net/publication/401375160\\_Impact\\_of\\_Artificial\\_Intelligence\\_on\\_Fraud\\_Detection\\_in\\_Retail\\_Banking\\_A\\_Quantitative\\_Study](https://www.researchgate.net/publication/401375160_Impact_of_Artificial_Intelligence_on_Fraud_Detection_in_Retail_Banking_A_Quantitative_Study)) - praca skupiająca się na wpływie elementu ludzkiego w pracy z AI, aspekty jak przejrzystość systemu czy wyjaśnialność algorytmów. W naszym przypadku mało przydatna przez brak elementu ludzkiego w projekcie.

Istnieje dużo innych prac dotyczących zagadnienia, jednak wszystkie opierają się na podobnych rozwiązaniach, niektóre z nich mają nawet tych samych autorów.

### 1. Opis zbioru

Zbiór “Banking Fraud Detection & Risk Analytics Dataset” to zbiór danych dotyczący wykrywania oszustw bankowych. Zawiera 10000 rekordów, gdzie

każdy wiersz to pojedyncza transakcja. Opisuje je 20 cech (kolumn) o różnych typach. W zbiorze nie występują puste wartości, zatem jest on kompletny.

```
- Dataset Shape -
(10000, 20)

- Dataset Information -
<class 'pandas.DataFrame'>
RangeIndex: 10000 entries, 0 to 9999
Data columns (total 20 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   transaction_id                        10000 non-null  int64
1   transaction_amount                    10000 non-null  float64
2   login_attempts                        10000 non-null  int64
3   device_risk_score                     10000 non-null  float64
4   transfer_frequency                    10000 non-null  int64
5   anomaly_score                         10000 non-null  float64
6   account_age_days                      10000 non-null  int64
7   transaction_time_hour                 10000 non-null  int64
8   failed_transactions_last_30d          10000 non-null  int64
9   avg_monthly_balance                   10000 non-null  float64
10  daily_transaction_count                10000 non-null  int64
11  geo_distance_km                       10000 non-null  int64
12  session_duration_minutes              10000 non-null  int64
13  transaction_velocity_score             10000 non-null  float64
14  payment_channel                       10000 non-null  str
15  authentication_type                   10000 non-null  str
16  card_present_flag                     10000 non-null  int64
17  international_transaction_flag         10000 non-null  int64
18  suspicious_ip_flag                    10000 non-null  int64
19  fraud_flag                            10000 non-null  bool
dtypes: bool(1), float64(5), int64(12), str(2)
```


Opis cech:

Zmienne można podzielić na podstawie ich typu:


- **Całkowite**

- Transaction\_id – unikalny identyfikator transakcji. Nie niesie żadnych informacji, więc pewnie nie będzie uwzględniony podczas treningu
- Login\_attempts – liczba prób zalogowania przed wykonaniem transakcji
- Transfer\_frequency - częstotliwość przelewów
- Account\_age\_days – wiek konta w dniach
- Transaction\_time\_hour – godzina wykonania transakcji (pełne od 0 do 23)
- Failed\_transactions\_last\_30d – liczba nieudanych transakcji w ciągu ostatnich 30 dni
- Daily\_transaction\_count – dzienna liczba transakcji

- Geo\_distance\_km - odległość w kilometrach (nie jest doprecyzowane co dokładnie oznacza, prawdopodobnie odległość transakcji (skąd dokąd))
- Session\_duration\_minutes – czas trwania sesji użytkownika
- **Zmiennoprzecinkowe**
  - Transaction\_amount - kwota
  - Device\_risk\_score - wskaźnik oceny ryzyka dla danego urządzenia
  - Anomaly\_score - wskaźnik oceny poziomu anomalii
  - Avg\_monthly\_balance - średnie miesięczne saldo na koncie
  - Transaction\_velocity\_score – wskaźnik “prędkości” (jak szybko następują po sobie przelewy)
- **Tekstowe**
  - Payment\_channel – użyty kanał (Mobile App, Web Banking, ATM (bankomat), POS (terminal))
  - Authentication\_type - sposób uwierzytelnienia (Biometric, OTP (One time password), Password Only, Two-Factor Authentication)
- **Binarne**
  - Fraud\_flag – czy oszustwo?
  - Card\_present\_flag – karta obecna przy transakcji (np. terminal)
  - International\_transaction\_flag – przelew zagraniczny
  - Suspicious\_ip\_flag – podejrzany adres IP




Zmienna docelowa (fraud\_flag) jest silnie niezbalansowana. Legalne transakcje stanowią około 87,5% zbioru, a oszustwa 12,5%.




## 2. Wykresy

Wykres przedstawia liczbę osób korzystających z różnych metod płatności. Najwięcej transakcji wykonuje się poprzez aplikację bankowe, zaraz po niej strony internetowe banków. Mniej wykorzystywane są bardziej tradycyjne metody jak płatności kartą bądź wypłacanie pieniędzy z bankomatu



Wykres przedstawia procent oszustw w podanych metodach płatności. Najmniej oszustw występuje podczas płatności kartą, co czyni tę metodę płatności najbezpieczniejszą. Następną metodą jest płatność poprzez stronę banku. Najgorzej przedstawia się wypłacanie gotówki z bankomatu.



Wykres kołowy przedstawia jakie metody uwierzytelnienia są używane podczas wykonywania transakcji

OTP(one time password): 42.1%


Biometric(Biometria): 15.9%

Tylko hasło: 18.2%

Dwu etapowa autoryzacja: 23.8%


Najbardziej wybieraną metodą autoryzacji jest one time password, w następnym wykresie zauważymy, że jest bardzo bezpieczną metodą autoryzacji. Mimo swojej popularności wychodzi najgorzej na tle pozostałych.

Mniej popularną, ale za to najbezpieczniejszą metodą okazuje się dwu etapowa autoryzacja



Wykres przedstawia procent oszustw w podanych metodach autoryzacji. Wszystkie są bardzo bezpieczne, mają ponad 80% bezpiecznych transakcji. Najbezpieczniejszą metodą okazuje się dwu etapowa autoryzacja, która ma prawie 90% bezpiecznych transakcji


1. Dwuetapowa autoryzacja: 88.4%/11.6%
2. Biometria : 87.9%/12.1%
3. Hasło: 87.2%/12.8%
4. Otp: 86.9%/13.15




Wkres przedstawia ilość wykonanych transakcji w danych godzinach.

Najwięcej przelewów/transakcji zostaje wykonana w godzinach 3,11,23.

Najmniej wykonuje się w godzinach 4 i 13




### 3. Macierz korelacji



Wykres przedstawia macierz korelacji, współczynniki korelacji mieszczą się w przedziale (-1, 1). Większość wartości pól jest bliska zera, oznacza to, że zmienne są od siebie niezależne. Wyjątkiem jest para `fraud_flag` i `anomaly_score`, współczynnik między nimi wynosi 0.675. Oznacza to dla nas im wyższe `anomaly_score` to prawdopodobieństwo, że transakcja zostanie oznaczona jako oszustwo.





Wykres przedstawia prawdopodobieństwo, że transakcja okaże się oszustwem.

Oceny anomalii (0.0; 0.5) procent oszustw nie przekracza 20%, co czyni transakcje z oceną anomalii z przedziału bezpiecznymi

Oceny anomalii (0.5; 0.8) procent oszustw gwałtownie wzrasta.

Oceny anomalii (0.8; 1) na tym przedziale procent, że dana transakcja jest oszustwem wnosi od ok 90%-100%