

The background of the slide features a blurred financial chart. It includes a line graph with white circular markers connected by thin lines, and a bar chart with orange bars. Some data points are labeled with numbers like '245.5', '153.102', and '154.178'.

Wpływ optymalizacji modeli na poziom wykrycia oszustw bankowych


Autorzy: Karolina Antonowicz, Marcin Zubowski, Borys Maksymiuk

Zbiór danych

Zbiór “Banking Fraud Detection & Risk Analytics Dataset” to zbiór danych dotyczący wykrywania oszustw bankowych. Zawiera 10000 rekordów, gdzie każdy wiersz to pojedyncza transakcja. Opisuje je 20 cech (kolumn) o różnych typach. W zbiorze nie występują puste wartości.

Zmienna docelowa (fraud_flag) jest silnie niezbalansowana. Legalne transakcje stanowią około 87,5% zbioru, a oszustwa 12,5%.





A large orange circle is positioned on the left side of the slide, partially cut off by the edge.

ANALIZA POTENCJALNYCH KANDYDATÓW NA MODEL


Braliśmy pod uwagę 5 rozwiązań:



- Regresja Logistyczna
- Sieć Neuronowa
- Drzewo Decyzyjne
- Las Losowy
- XGBoost

Po analizie oraz porównaniu (więcej w pliku kandydaci.pdf) stwierdziliśmy że najlepsze w naszym projekcie będą Drzewo Decyzyjne oraz XGBoost.




Decision Tree Visualization







Po implementacji modeli, **XGBoost** osiągnął znacznie wyższy F1-Score, więc to on został wybrany do dalszej optymalizacji. Wykonaliśmy strojenie hiperparametrów oraz sprawdziliśmy jak model się zachowa po treningu na zbiorze zmniejszonym o najmniej istotne cechy.




10 NAJMNIEJ ważnych cech dla modelu (Kandydaci do usunięcia)




Porównanie modelu XGBoost przed i po strojeniu parametrów




Wpływ usunięcia 10 najsłabszych cech na skuteczność modelu



Wpływ redukcji cech na ZOPTYMALIZOWANY model XGBoost



Ostateczne podsumowanie wyników modelu XGBoost



Wnioski końcowe

- Kompromis między czułością a precyzją: Proces strojenia parametrów znacząco podniósł czułość modelu (Recall), co wiązało się ze spadkiem precyzji. W kontekście wykrywania oszustw finansowych jest to jednak zjawisko pożądane – priorytetem jest detekcja jak największej liczby prawdziwych nadużyć, nawet kosztem weryfikacji fałszywych alarmów.
- Skuteczna redukcja wymiarowości: Usunięcie znacznej części najmniej istotnych cech nie pogorszyło wyników, a w zestawieniu ze zoptymalizowanym modelem wręcz nieznacznie zwiększyło jego skuteczność.
- Optymalizacja zasobów IT: Projekt udowodnił, że poprzez świadome odrzucenie szumu informacyjnego można osiągnąć wyższą jakość predykcji, jednocześnie znacząco odciążając system z przetwarzania mało istotnych danych.