

Przedmiot: Przegląd metod i narzędzi AI Temat: Praca domowa 1 – Analiza danych zbioru Iris oraz grupowanie K-Means (grupa B)	Prowadzący: Kajetan Zarzycki
Wykonał: <i>Marcin Zubowski, numer PS: 2, numer indeksu: 119084</i> <i>Kierunek Data Science, semestr II</i>	Data: 29.03.2026

Spis treści

1. Wstęp	1
a. Cel ćwiczenia	1
b. Wykorzystane narzędzia	2
c. Opis zbioru danych	2
2. Wykonanie	2
a. Przygotowanie danych	2
b. Grupowanie i metryki	3
c. Wizualizacja	3
3. Grupowanie na pełnym zbiorze	3
a. Wyniki metryk	3
b. Wizualizacja	4
4. Grupowanie na podstawie pojedynczych cech	4
a. Wyniki metryk	4
b. Wizualizacja	5
5. Podsumowanie	8

1. Wstęp

a. Cel ćwiczenia

Celem projektu jest analiza zbioru danych Iris, pogrupowanie go za pomocą algorytmu uczenia nienadzorowanego K-Means, a następnie ocena jakości tego pogrupowania za pomocą metryk klasyfikacyjnych oraz wizualizacja wyników. Pełny kod źródłowy projektu oraz pozostałe pliki dostępne są w repozytorium GitHub:

https://github.com/MerLinh-0/PMN-26L-Zubowski-Marcin/tree/main/Task_1

b. Wykorzystane narzędzia

Program napisano w języku programowania Python (wersja 3.12.9) w zintegrowanym środowisku programistycznym Visual Studio Code. Do poprawnego działania programu wymagane są dodatkowe biblioteki:

- Sklearn – algorytm K-Means, metryki, TSNE
- Pandas – wczytanie, wybór i analiza danych
- Matplotlib – wykresy

Wszystkie niezbędne pakiety zapisane są w pliku *requirements.txt* w repozytorium GitHub.

c. Opis zbioru danych

Wszystkie operacje wykonywane są na zbiorze „Iris”. Zawiera on dane o próbkach kwiatów. Znajduje się tam dokładnie 150 rekordów trzech różnych gatunków (po 50 na gatunek). Zbiór posiada następujące atrybuty:

- Sepal length – długość działki kielicha
- Sepal width – szerokość działki kielicha
- Petal length – długość płatk
- Petal width – szerokość płatk
- Species – gatunek
 - Iris Setosa
 - Iris Versicolor
 - Iris Virginica

Pierwsze cztery atrybuty są wartościami numerycznymi podanymi w centymetrach. Zbiór nie posiada brakujących wartości bądź błędów logicznych (literówki, niepoprawne typy czy nienaturalnie odstające wartości).

2. Wykonanie

a. Przygotowanie danych

Pierwszą rzeczą jest załadowanie danych z pliku *iris.data* za pomocą biblioteki *pandas*, a dokładniej funkcji *read_csv*. Następnie w celu głębszej analizy podzielono zadanie na 2 etapy: etap 1 – grupowanie wszystkich cech, etap 2 – grupowanie pojedynczych cech. Umożliwi to zdefiniowanie, które cechy zbioru idealnie rozdzielają gatunki, a które są do siebie bardzo podobne. Ze względu na to, że K-Means to algorytm

uczenia nienadzorowanego, rozdzielamy gatunek (klasę) od wartości numerycznych. Gatunki dodatkowo zamieniamy na wartości numeryczne od 0 do n (gdzie n to ilość klas). Tak wyodrębnione klasy posłużą nam później do porównania wyników.

b. Grupowanie i metryki

Gdy mamy już przygotowane dane możemy przejść do grupowania ich za pomocą algorytmu K-Means (sklearn). Przyjmuje on parametr *n_clusters*, który odpowiada za ilość utworzonych klas oraz *random_state* zapewniający powtarzalność wyników (w wykonanym zadaniu przyjmuje on wartość 0), funkcja przyjmuje jeszcze wiele innych parametrów, lecz nie będą nam one na ten moment potrzebne. Algorytm przypisuje klastrom identyfikatory liczbowe, lecz robi to zupełnie losowo, dlatego należy przejść po każdym z nich, znaleźć dominantę, a następnie podmienić identyfikator na rzeczywistą klasę. Dopiero takie dane pozwalają na obliczenie poprawnych metryk takich jak accuracy, precision, recall, f1-score czy macierz pomyłek (również przy użyciu biblioteki sklearn).

c. Wizualizacja

Na sam koniec przystępujemy do generowania wykresów. W przypadku pojedynczych cech będą to proste linie z odpowiednio pokolorowanymi punktami. Problem jednak pojawia się w przypadku całego zbioru, ponieważ posiada on 4 cechy, a to odpowiada 4 wymiarom. Zatem musimy wykorzystać algorytm t-SNE, który zredukuje wymiarowość, co pozwoli nam narysować wykres 2D. Dokładne metryki oraz wizualizacja przedstawione są w następnych punktach.

3. Grupowanie na pełnym zbiorze

a. Wyniki metryk


- Accuracy (dokładność) – ogólny procent poprawnych trafień modelu na całym zbiorze – **0,8867** (89%)
- Precision (precyzja) – określa jak często model faktycznie ma rację, gdy przypisze kwiat do jakiegoś gatunku – **0,8979** (90%)
- Recall (czułość) – wysoka czułość oznacza, że model rzadko przegapia kwiaty, których szuka – **0,8867** (89%)
- F1-score – łączy precyzję i czułość w jedną wartość – **0,8853** (86%)
- Macierz pomyłek – pokazuje tabelę, która świetnie przedstawia, gdzie model się pomylił i które klasy sprawiają mu największy problem.

$$\begin{bmatrix} 50 & 0 & 0 \\ 0 & 47 & 3 \\ 0 & 14 & 36 \end{bmatrix}$$

Wynika stąd, że model świetnie pogrupował klasę 0 (Iris Setosa), ale ma problemy z Iris Versicolour oraz Iris Virginica.

b. Wizualizacja

Poprzedni wniosek świetnie zobrazuje poniższy wykres:



O ile *Setosa* (fiolet) jest świetnie oddzielona od reszty, to pozostałe dwa gatunki znajdują się bardzo blisko siebie i gdyby nie kolor to ciężko byłoby je odróżnić. Pokrywa się to z błędami z naszej macierzy pomyłek.

4. Grupowanie na podstawie pojedynczych cech


a. Wyniki metryk

Metryka Cecha	Accuracy	Precision	Recall	F1- score	Macierz pomyłek
Sepal length	0,72	0,73	0,72	0,72	$\begin{bmatrix} 40 & 10 & 0 \\ 5 & 31 & 14 \\ 1 & 12 & 37 \end{bmatrix}$
Sepal width	0,56	0,60	0,56	0,57	$\begin{bmatrix} 32 & 1 & 17 \\ 2 & 21 & 27 \\ 8 & 11 & 31 \end{bmatrix}$
Petal length	0,95	0,95	0,95	0,95	$\begin{bmatrix} 50 & 0 & 0 \\ 0 & 46 & 4 \\ 0 & 3 & 47 \end{bmatrix}$
Petal width	0,96	0,96	0,96	0,96	$\begin{bmatrix} 50 & 0 & 0 \\ 0 & 48 & 2 \\ 0 & 4 & 46 \end{bmatrix}$


b. Wizualizacja

Wykresy można podzielić na takie, które dobrze rozdzielają klasy, i takie, gdzie algorytm sobie nie radzi.

Wizualizacja grupowania K-means dla sepal_length




Wizualizacja grupowania K-means dla sepal_width




Dla cech *sepal_length* oraz *sepal_width* ciężko podzielić zbiór

Wizualizacja grupowania K-means dla petal_length



Wizualizacja grupowania K-means dla petal_width



Za to dla wartości *petal_length* i *petal_width* świetnie widać podział. Pokrywa się to z zamieszczoną wcześniej tabelą metryk, gdzie owe cechy miały najlepsze wyniki.

5. Podsumowanie

Wykonany projekt świetni przedstawia skuteczność algorytmu uczenia nienadzorowanego jakim jest K-Means do grupowania danych. Działania na pełnym zbiorze Iris zwróciły wysoką zgodność klas z rzeczywistym podziałem gatunków. Jak potwierdzają metryki i wykres z użyciem t-SNE, model świetnie izoluje gatunek *Setosa*, lecz napotyka małe problemy przy podobnych do siebie *Versicolor* i *Virginica*.

Dodatkowa analiza pojedynczych cech pokazała również jak ważny jest dobór odpowiednich cech. W momencie, gdy niektóre pozwalają niemal idealnie oddzielić od siebie klastry, pozostałe jedynie utrudniają grupowanie.

Podsumowując, sukces algorytmu nie zależy jedynie od optymalizacji, a od jakości i użyteczności dostarczonych danych wejściowych.